

JAIME PÉREZ SÁNCHEZ

TRABAJO FIN DE GRADO

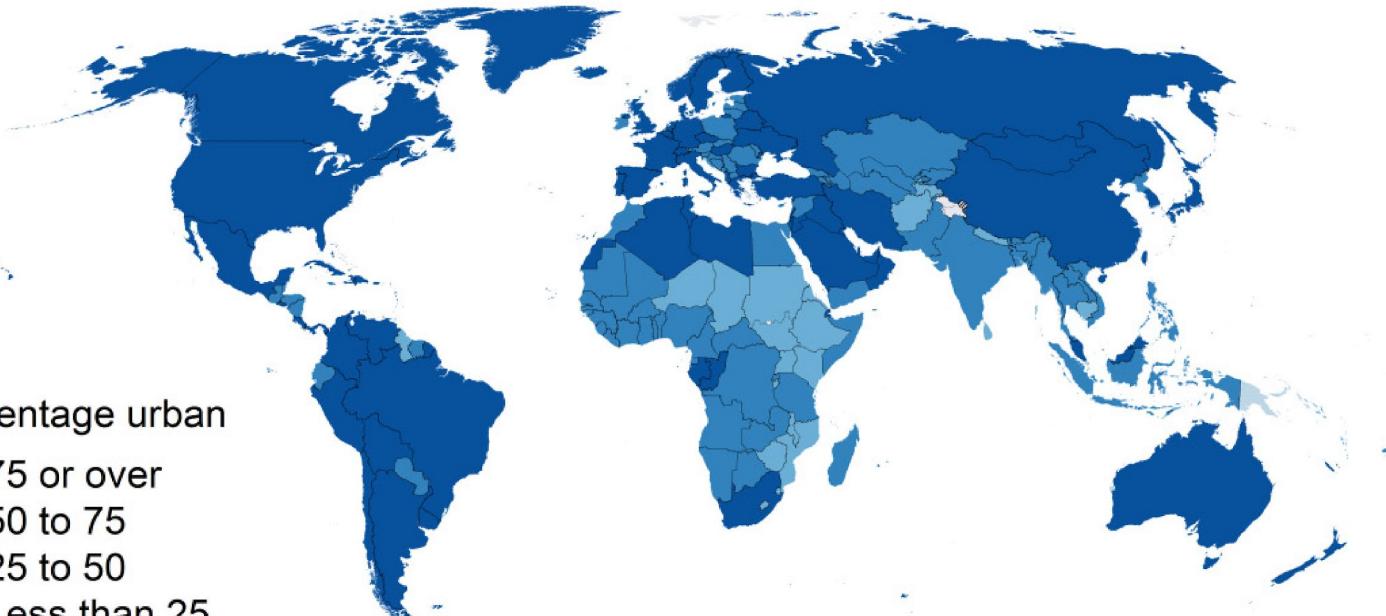
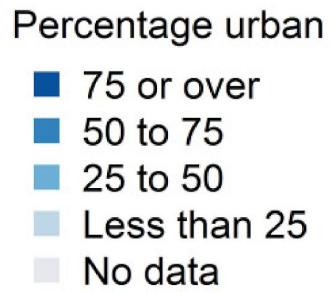


**IMPLEMENTACIÓN DEL MODELADO DE TEMPERATURA
MEDIANTE ALGORÍTMOS DE APRENDIZAJE AUTOMÁTICO
PARA SISTEMAS DE REFRIGERACIÓN POR INMERSIÓN EN
HIDRO-FLUORO-ÉTERES**

ÍNDICE

1. Motivación
2. Objetivos
3. Estado del arte
4. Solución
5. Experimentos
6. Conclusiones y líneas futuras

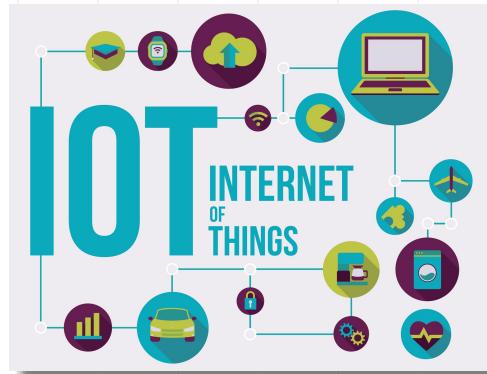
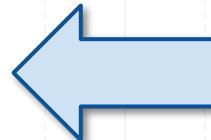
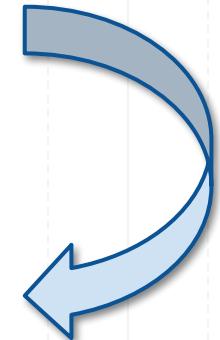
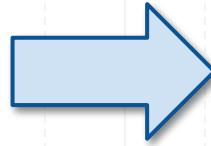
2050

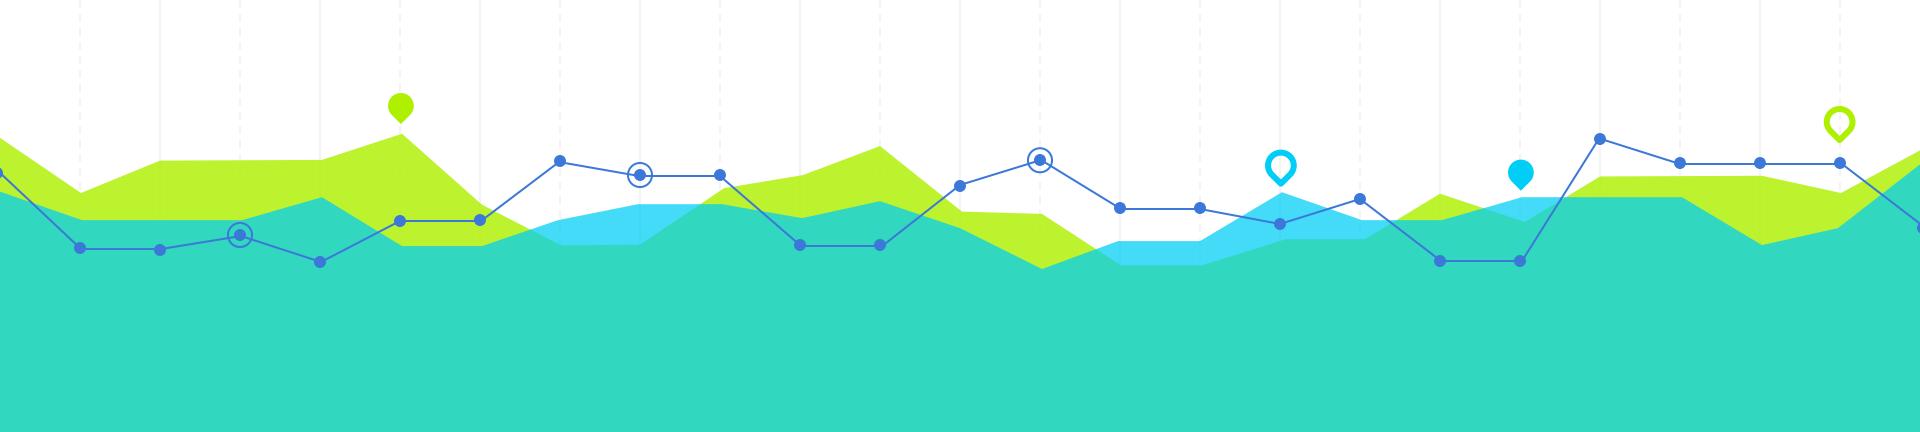


Fuente: Organización de las Naciones Unidas, ONU

Problemas derivados:

- Contaminación
- Consumo energético
- Reparto ineficiente de recursos



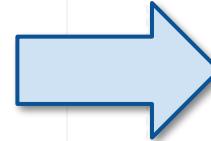


100.000.000.000

Número de dispositivos IoT en el año 2030

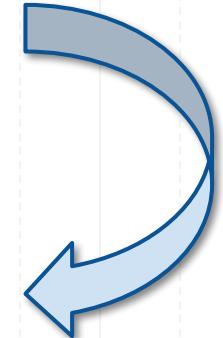
Fuente: IHS Markit

CL^OUD COMPUTING



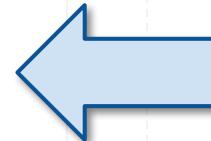
Problemas futuros:

- Saturación de *Data Centers* y red
- Altas latencias
- Alto coste de computación



Retos más importantes:

- Refrigeración independiente de la ubicación y climatología
- Consumo energético
- Tamaño (Densidad de potencia)

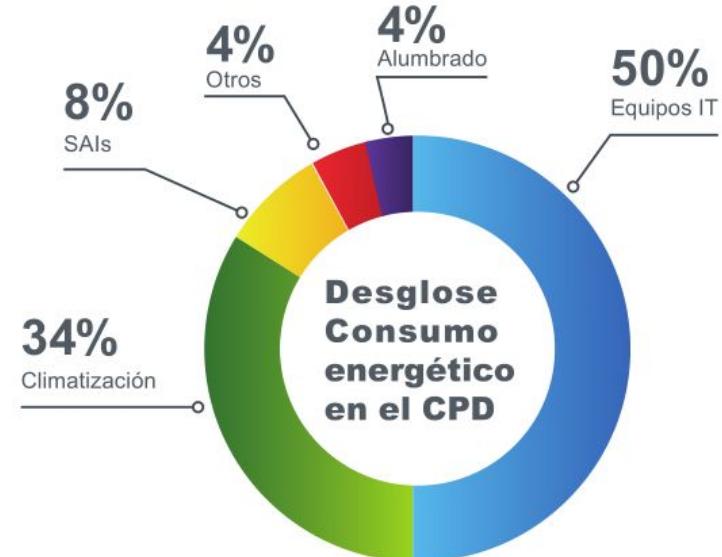


POWER USAGE EFFECTIVENESS (PUE)

$$PUE = \frac{\text{Energía Total DC}}{\text{Energía Equipos IT}}$$

* $PUE_{\text{media mundial}} = 1,79$

* $PUE_{\text{ideal}} = 1$



MÉTODOS DE REFRIGERACIÓN EN CENTROS DE DATOS

- Corrientes de aire
- Agua
- Inmersión

- Alto consumo energético
- Densidad de potencia baja
- *Overcooling, turbulencias y puntos calientes*



MÉTODOS DE REFRIGERACIÓN EN CENTROS DE DATOS

- Corrientes de aire

- Agua

- Inmersión

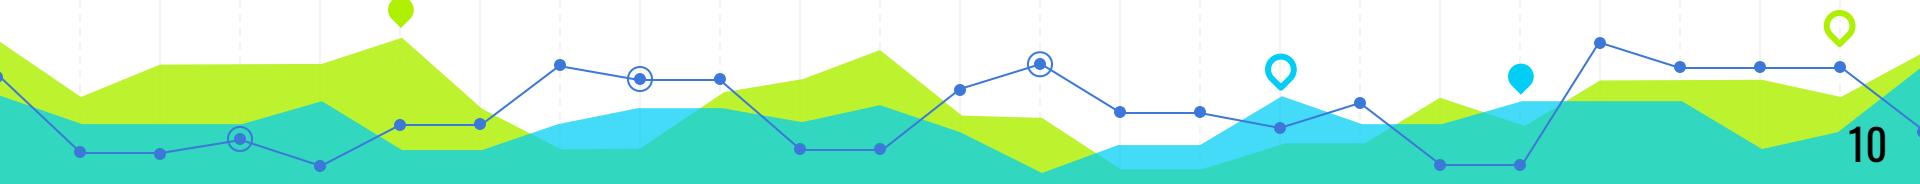
- Densidad de potencia media - baja
- Alto consumo energético
- Riesgo de fugas y corrosión



MÉTODOS DE REFRIGERACIÓN EN CENTROS DE DATOS

- Corrientes de aire
- Agua
- Inmersión

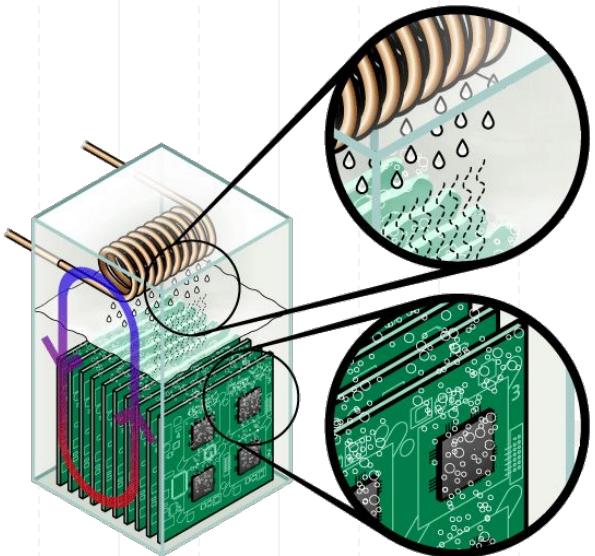
- Poco desarrollado
- Alta densidad
- Líquidos en contacto directo con los componentes electrónicos



ÍNDICE

1. Motivación
- 2. Objetivos**
3. Estado del arte
4. Solución
5. Experimentos
6. Conclusiones y líneas futuras

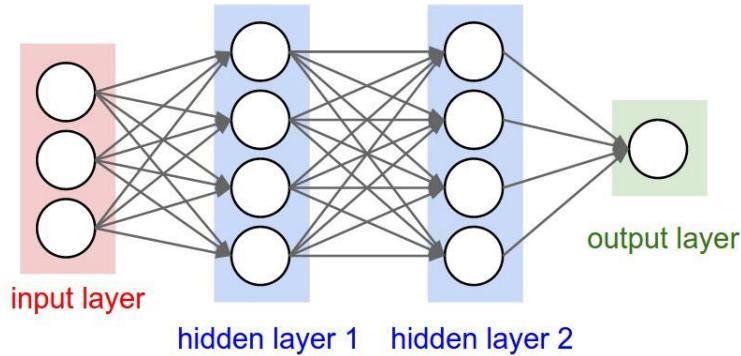
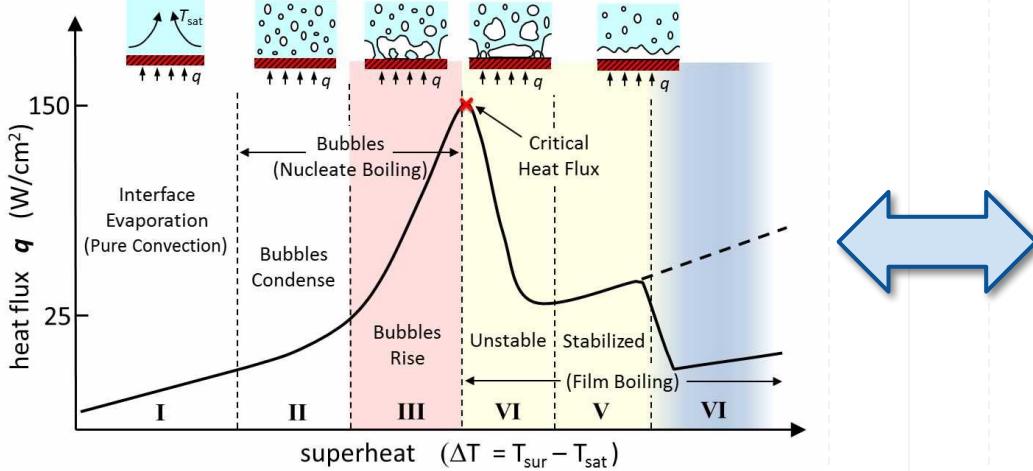
REFRIGERACIÓN POR INMERSIÓN PASIVA BIFASE EN HIDRO-FLUORO-ÉTERES



3M
Novec

- No conductor eléctrico
- Buen conductor térmico
- Respetuoso con el medio ambiente
- Punto de ebullición: 61 °C
- Usado en limpieza de equipos y extinción de incendios

REFRIGERACIÓN POR INMERSIÓN PASIVA BIFASE EN HIDRO-FLUORO-ÉTERES



Modelos predictivos de temperatura



¿CÓMO RESUELVE NUESTRA SOLUCIÓN LOS RETOS DE EDGE COMPUTING?

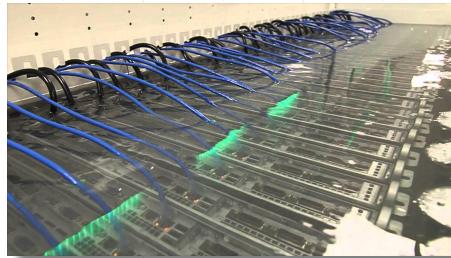
- **Refrigeración** independiente del clima
- Reducir el **consumo energético** de refrigeración por ser pasiva
 - ↳ $PUE \approx 1$
- Aumenta la **densidad de potencia** por rack (De 40 kW a 250 kW)
 - ↳ Reduce el **tamaño** de los *Edge Data Center*
- Simplifica el diseño y la fabricación de *Data Centers*

ÍNDICE

1. Motivación
2. Objetivos
- 3. Estado del arte**
4. Solución
5. Experimentos
6. Conclusiones y líneas futuras

MÉTODOS DE REFRIGERACIÓN POR INMERSIÓN

● Inmersión en una fase



● Inmersión en dos fases



MODELOS PREDICTIVOS DE TEMPERATURA

- Métodos analíticos

- Métodos metaheurísticos

↪ RNN

- Tarea tediosa y soluciones poco precisas para sistemas complejos
- Requieren conocimiento profundo del problema

MODELOS PREDICTIVOS DE TEMPERATURA

- Métodos analíticos
- Métodos metaheurísticos

↪ RNN

- Métodos aproximados
- Optimización automática
- No es necesario un conocimiento profundo del problema



MODELOS PREDICTIVOS DE TEMPERATURA

- Métodos analíticos

- Métodos metaheurísticos

↳ RNN

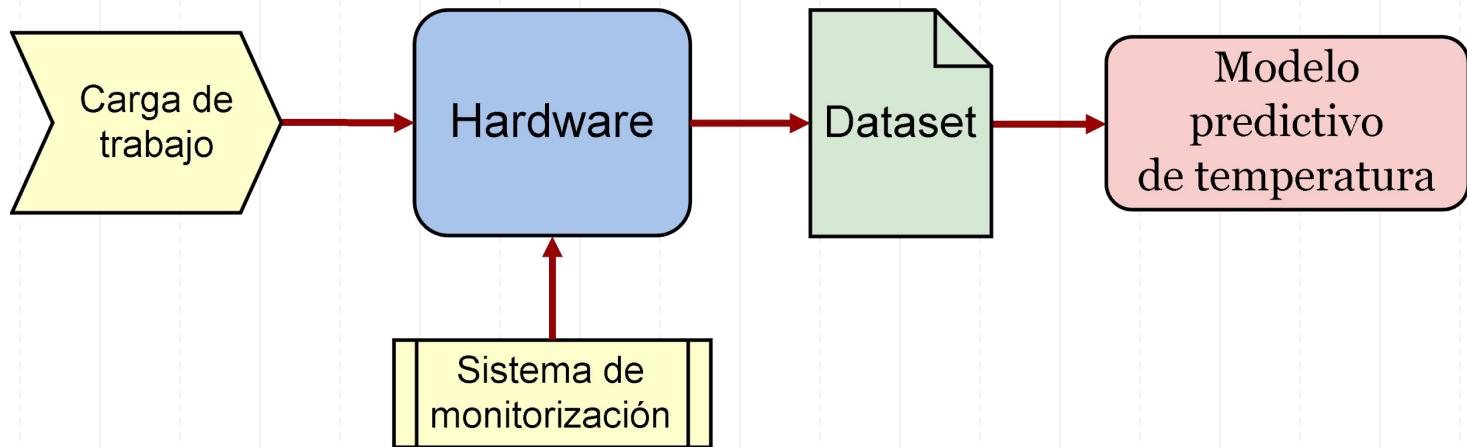
- Capaces de analizar series temporales
- Facilidad de implementación
(*Keras* y *TensorFlow*)



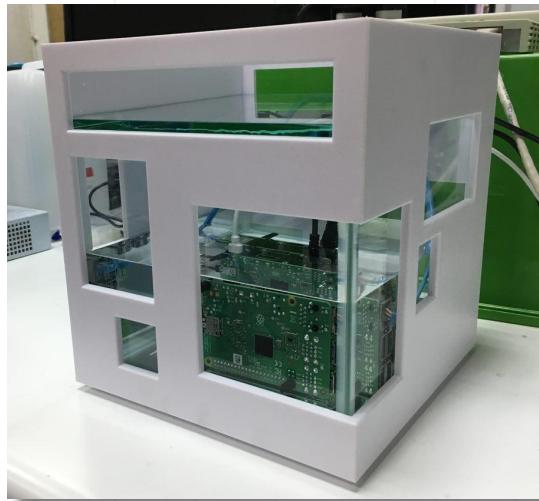
ÍNDICE

1. Motivación
2. Objetivos
3. Estado del arte
- 4. Solución**
5. Experimentos
6. Conclusiones y líneas futuras

ESQUEMA DE LA SOLUCIÓN

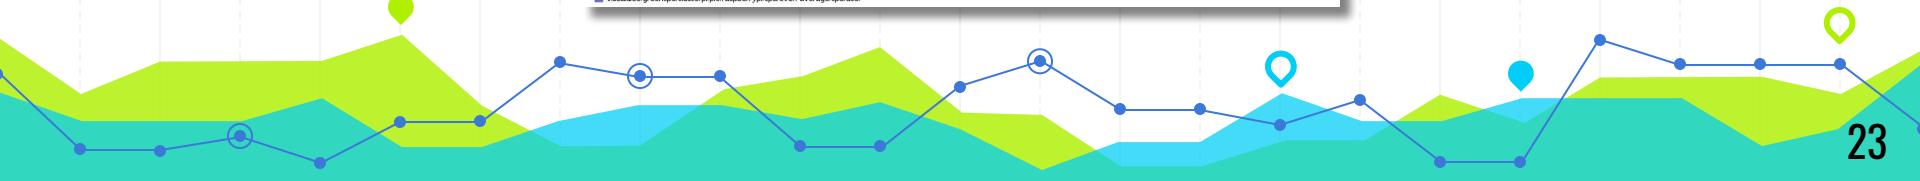
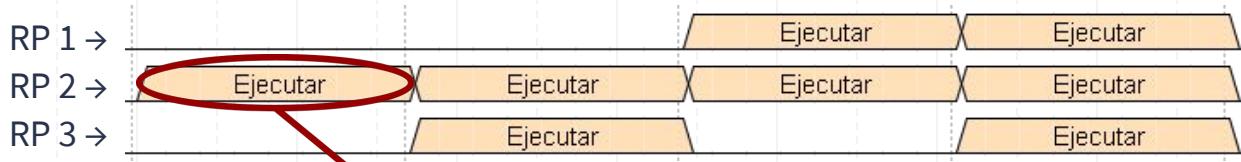


HARDWARE: CLUSTER DE RASPBERRY PI 3 MODEL B+



CARGA DE TRABAJO

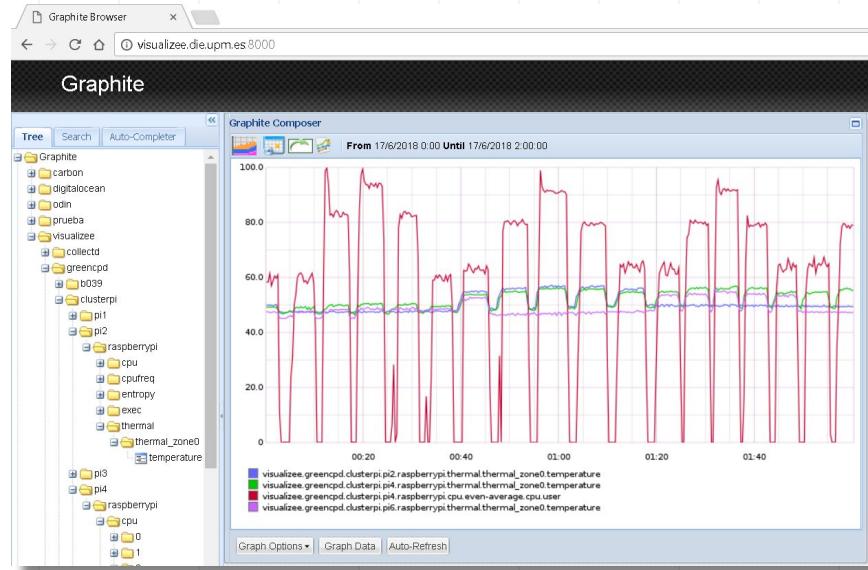
DATA ANALYTICS: PREDICCIÓN DE CONTAMINACIÓN AMBIENTAL



SISTEMA DE MONITORIZACIÓN: COLLECTD Y GRAPHITE

Métricas seleccionadas:

- Temperatura (RP 1)
- Temperatura (RP 2)
- Temperatura (RP 3)
- Utilización de CPU (RP 2)
- Frecuencia de CPU (RP2)



MODELO PREDICTIVO DE TEMPERATURA

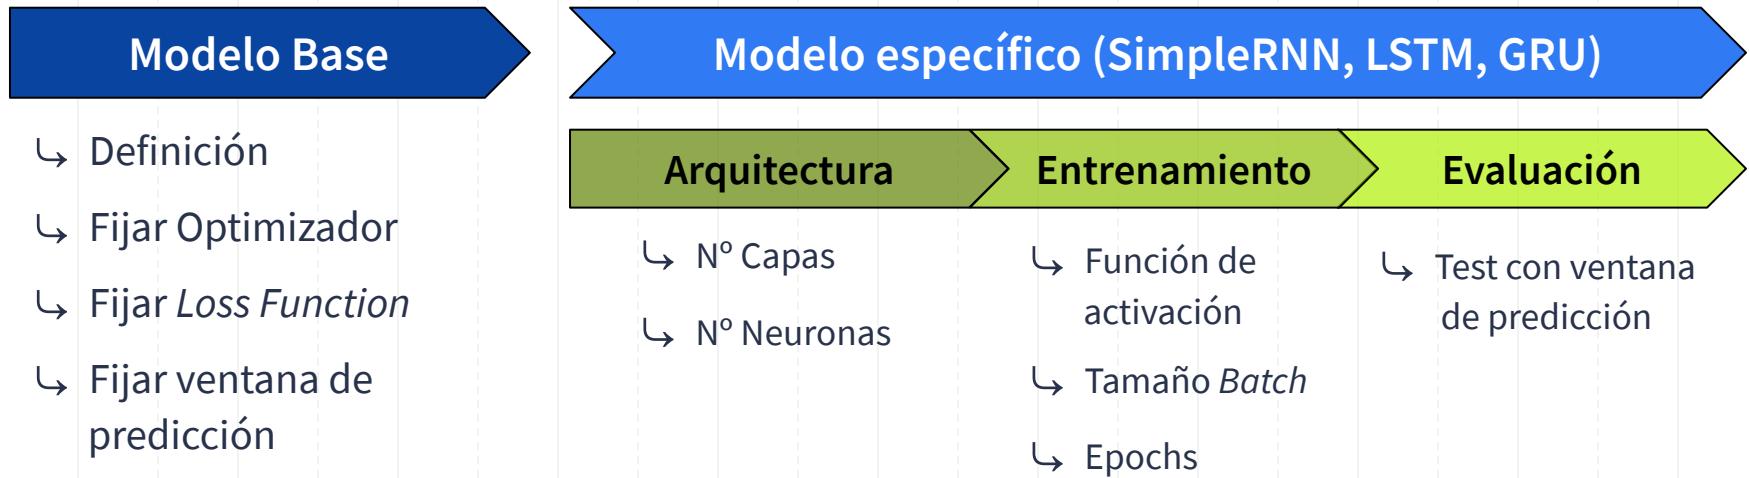
- Software: Keras sobre *TensorFlow*, *numpy*, *pandas*, *scikit-learn*.
- Hiperparámetros variables: Función de cálculo de error, optimizador, función de activación, estructura neuronal, tamaño de *Batch*, *Epochs*...
- Métricas de evaluación: MAE \pm STD ($^{\circ}\text{C}$), MAPE (%), Coeficiente de determinación R^2 (%), Error Máx ($^{\circ}\text{C}$), Error Máx Relativo(%), RMSD ($^{\circ}\text{C}$).



ÍNDICE

1. Motivación
2. Objetivos
3. Estado del arte
4. Solución
- 5. Experimentos**
6. Conclusiones y líneas futuras

ESQUEMA DE LOS EXPERIMENTOS



MODELO BASE

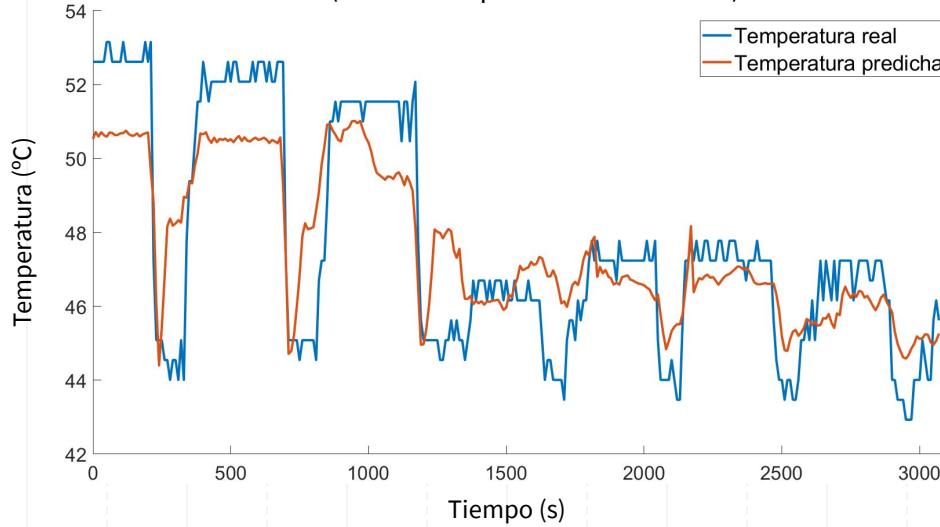
Función activación	Tamaño Batch	Epochs	Estructura neuronal
tanh	65	80	2 capas LSTM: 128 + 64 neuronas

Optimizador	Loss Function	Ventana temporal
Nadam	MAE	1 minuto



MODELO BASE

Test (ventana de predicción: 1 minuto)

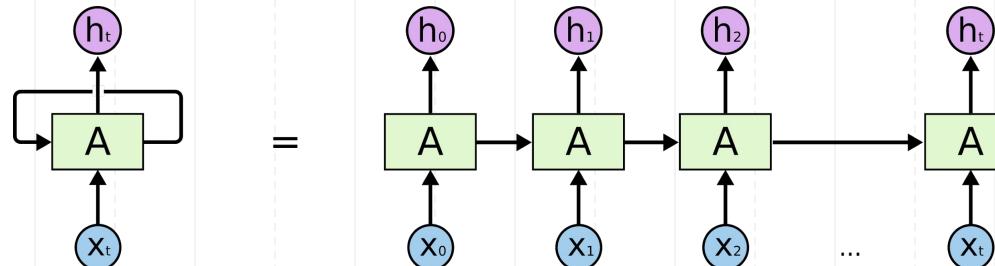


MAE ± STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
0.96 ± 1.093	2.058	71.883	6.362	14.457	1.455



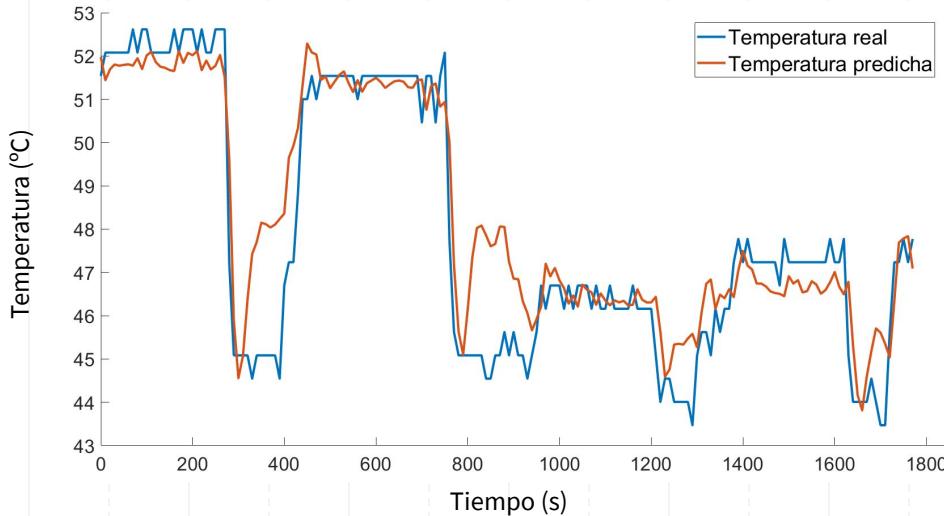
RED BASADA EN SIMPLE RNN

Función activación	Tamaño Batch	Epochs	Estructura neuronal
tanh	95	140	1 capa: 256 neuronas



RED BASADA EN SIMPLE RNN

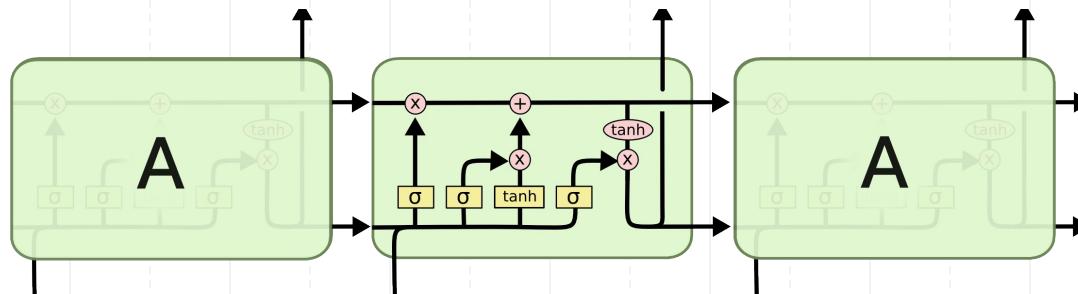
Test (ventana de predicción: 1 minuto)



MAE \pm STD °C	MAPE %	R ²	MáxAE °C	MáxAPE %	RMSD °C
0.836 \pm 0.842	1.8	83.897	3.688	8.281	1.187

RED BASADA EN LSTM

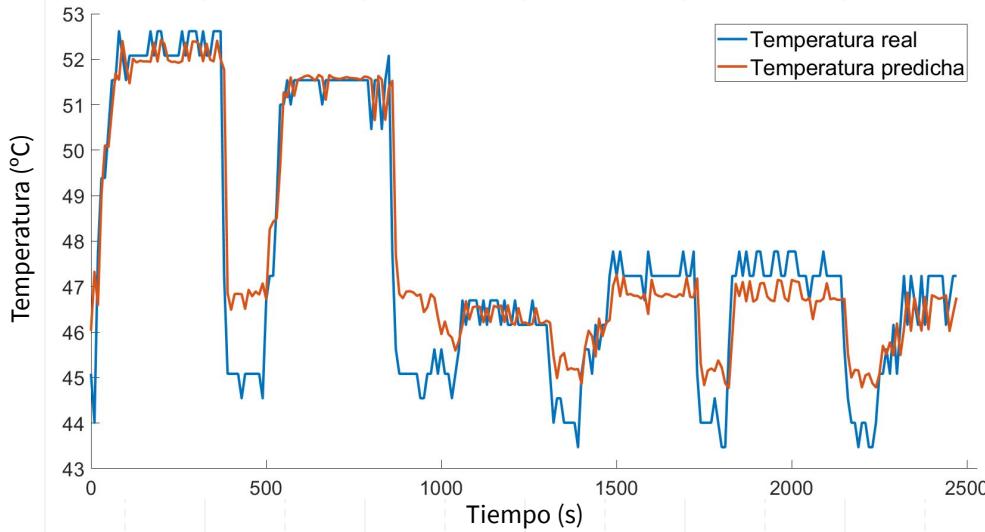
Función activación	Tamaño Batch	Epochs	Estructura neuronal
tanh	65	210	1 capa: 2 neuronas



32

RED BASADA EN LSTM

Test (ventana de predicción: 1 minuto)

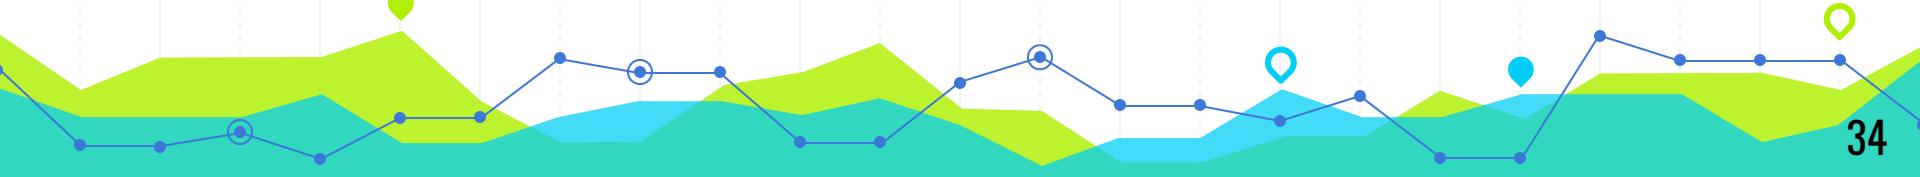
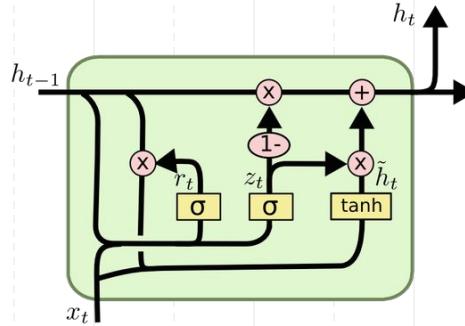


MAE \pm STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
0.711 \pm 0.658	1.535	87.527	4.535	9.6	0.969



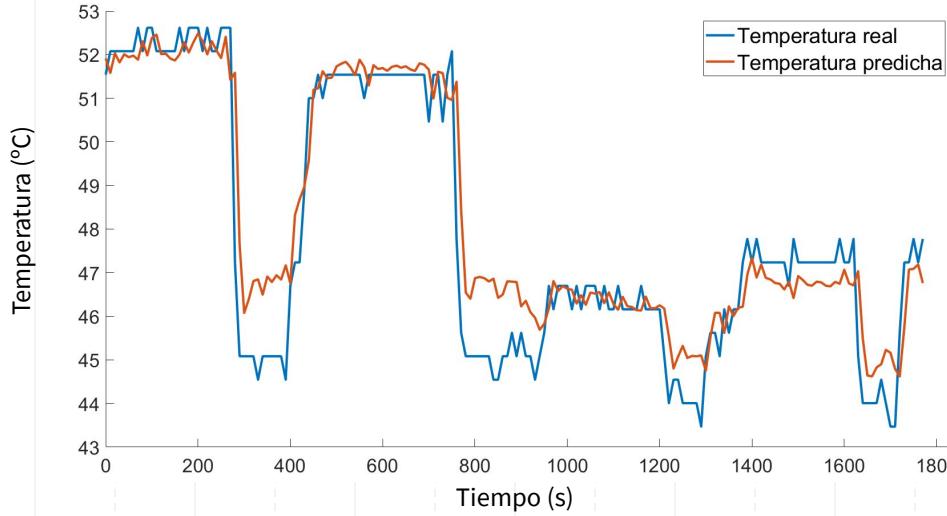
RED BASADA EN GRU

Función activación	Tamaño Batch	Epochs	Estructura neuronal
tanh	95	120	1 capa: 4 neuronas

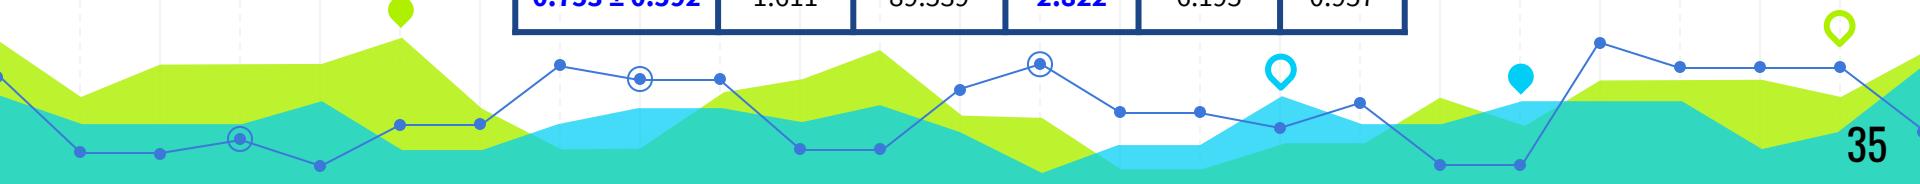


RED BASADA EN GRU

Test (ventana de predicción: 1 minuto)

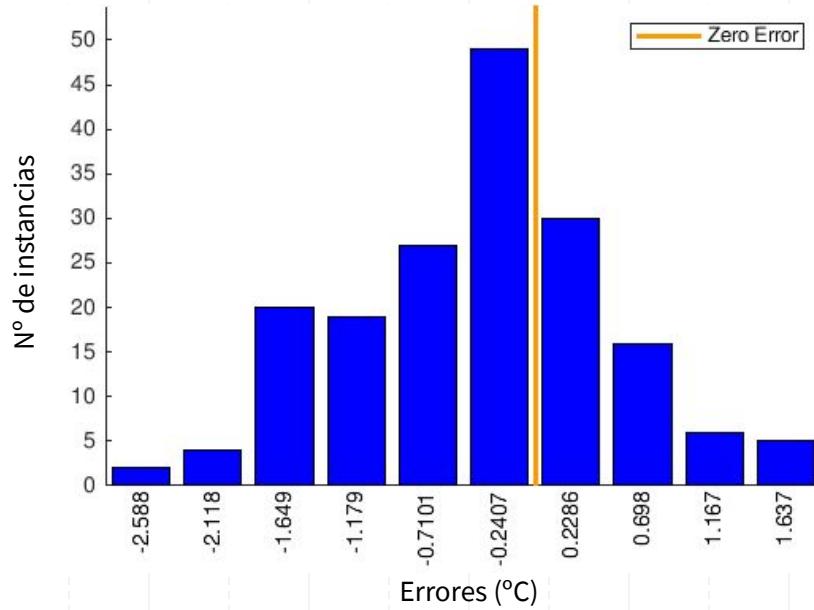


MAE ± STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
0.753 ± 0.592	1.611	89.539	2.822	6.195	0.957



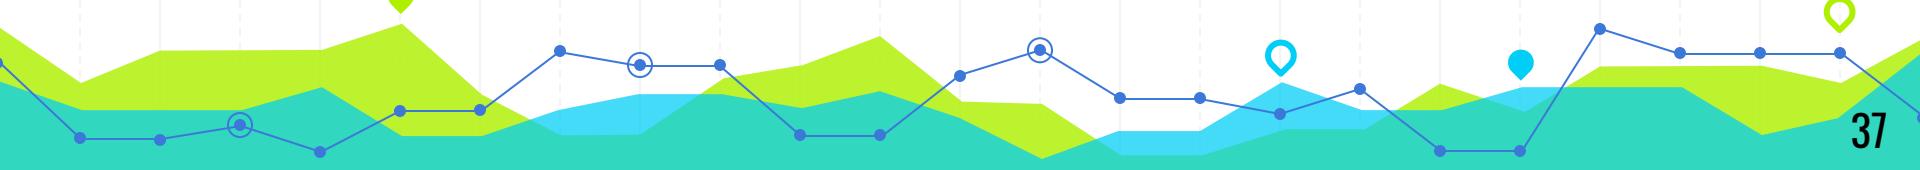
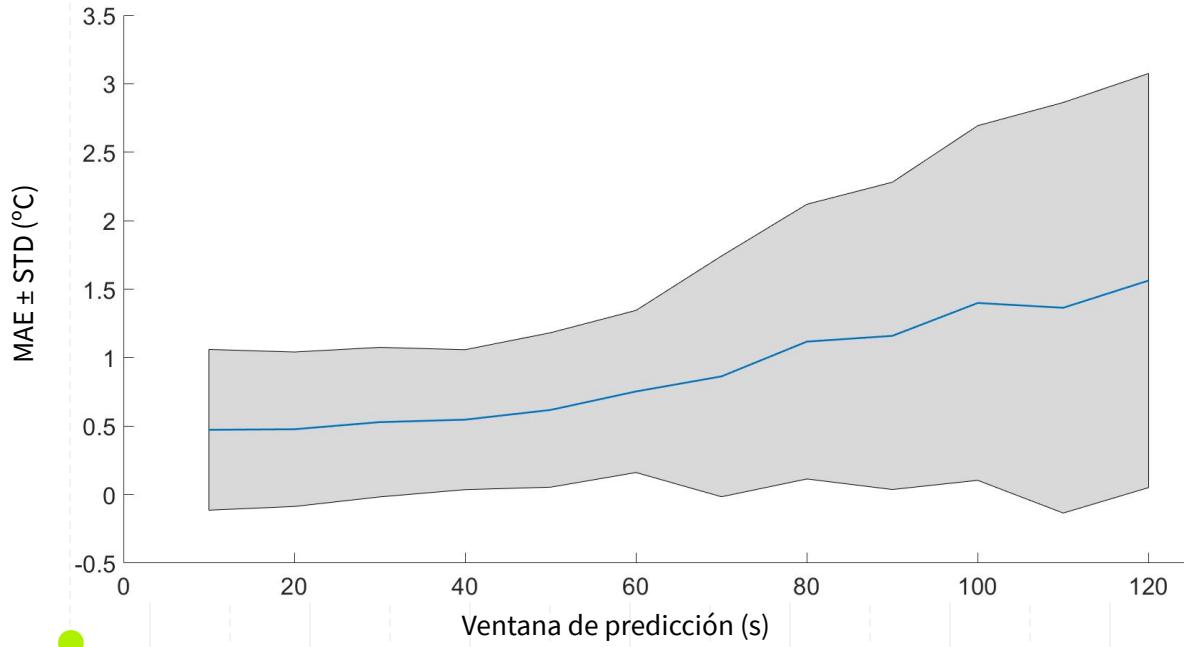
RED BASADA EN GRU

Histograma de errores



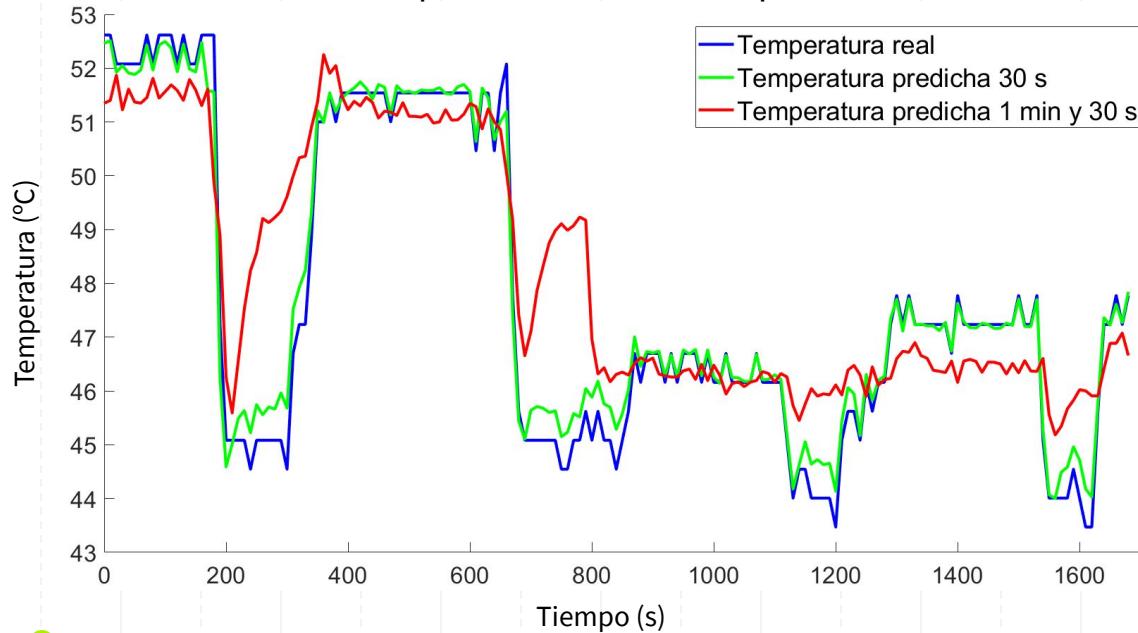
RED BASADA EN GRU

Evolución MAE ± STD



RED BASADA EN GRU

Test comparación ventanas de predicción



ÍNDICE

1. Motivación
2. Objetivos
3. Estado del arte
4. Solución
5. Experimentos
- 6. Conclusiones y líneas futuras**

RESUMEN DEL TRABAJO REALIZADO

- **Estudio previo** acerca de redes neuronales artificiales
- Montaje **Hardware** de un cluster *Raspberry Pi 3 Model B+*
- Diseño de una **carga de trabajo** basada en *Data Analytics*
- Implementación de un **sistema de monitorización** y almacenamiento de los datos capturados
- **Modelo predictivo** mediante RNN tipo GRU con ventana temporal de **1 min**: ($MAE \pm STD = 0,753 \pm 0,592 \text{ } ^\circ\text{C}$, Error Máximo = $2,822 \text{ } ^\circ\text{C}$)



CONCLUSIONES

- Solución para el despliegue de *Edge Data Centers* en núcleos urbanos: refrigeración pasiva bifase
 - ↳ Alta densidad de potencia (250 kW/rack) reduciendo el **tamaño**
 - ↳ Reducir **consumo energético** de refrigeración ($PUE \approx 1$)
 - ↳ Refrigeración **independiente del clima**
 - ↳ **Simplifica** el diseño y la fabricación de Data Centers
- Modelo predictivo de temperatura → **Arrastre de calor máximo** →
→ **Sistemas muy optimizados**

LÍNEAS FUTURAS

- Experimentación en tanque sellado con placas base de servidores
- Optimización y automatizado del entrenamiento de modelos predictivos → **Reducir intervención humana al mínimo**
- Experimentación y comparación con otros líquidos refrigerantes o mezclas de varios de ellos → **Arrastre de calor óptimo**

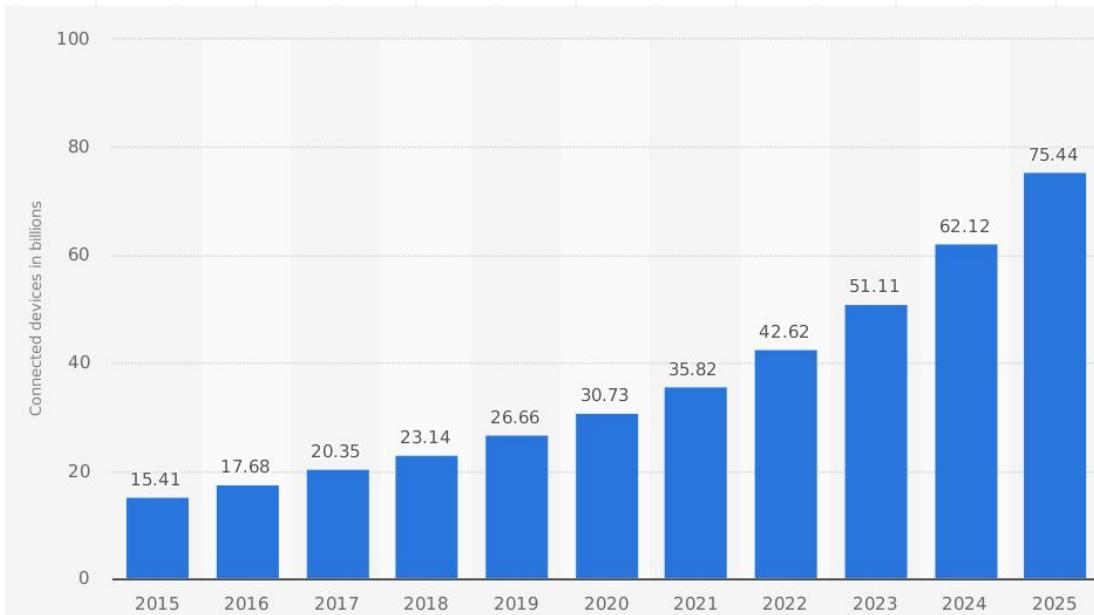
¡GRACIAS!



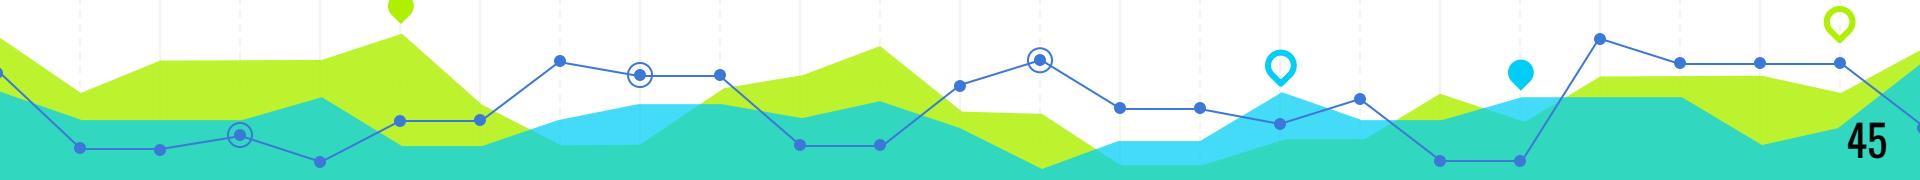
¡GRACIAS!



EVOLUCIÓN DEL Nº DE DISPOSITIVOS IoT



Evolución número de dispositivos IoT en miles de millones, IHS Markit



CONSUMO ENERGÉTICO DE DATA CENTERS

- Tianhe-2 (Top 1) > 200.000 MWh anuales
- 2020: Top 1 CPD \approx 1 Central Nuclear
- En el mundo:

500 000 CPDs

Energía: 200 000 000 000 € / año

FUNCIÓN DE CÁLCULO DEL ERROR

<i>Loss Function</i>	MAE \pm STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
MSE	1.866 \pm 1.288	3.919	42.787	6.165	14.009	2.267
MAE	1.313 \pm 0.929	2.758	71.186	4.954	11.258	1.609
MAPE	4.696 \pm 2.997	9.501	- 245.3	10.168	19.13	5.570
MSLE	2.061 \pm 1.437	4.263	29.741	6.718	15.265	2.513
Log cosh	1.848 \pm 1.24	3.83	44.904	5.877	13.355	2.225
Binary CrossEntropy	1.676 \pm 1.205	3.538	52.579	5.982	13.593	2.064

OPTIMIZADOR

Optimizador	MAE ± STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
SGD	1.465 ± 1.445	3.186	52.844	5.962	13.223	2.058
RMSprop	1.308 ± 1.036	2.784	69.011	5.368	12.198	1.668
Adagrad	1.848 ± 1.587	4.021	33.93	6.281	14.111	2.437
Adadelta	2.449 ± 1.436	5.262	10.305	6.815	15.677	2.839
Adam	1.405 ± 1.034	2.977	66.124	5.119	11.541	1.745
Adamax	1.23 ± 1.211	2.642	66.825	5.288	11.871	1.727
Nadam	1.313 ± 0.929	2.758	71.186	4.954	11.258	1.609

OPTIMIZACIÓN DE ESTRUCTURA NEURONAL

Estructura (nº neuronas)	MAE ± STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
1 capa (16)	1.039 ± 1.063	2.222	75.405	6.796	15.443	1.486
1 capa (64)	1.04 ± 1.13	2.244	73.741	6.598	14.992	1.536
1 capa (128)	1.107 ± 0.925	2.374	76.835	5.56	12.635	1.443
1 capa (256)	1.09 ± 0.832	2.33	79.071	4.941	11.227	1.371
2 capas (8, 8)	1.089 ± 1.213	2.354	70.397	5.906	13.422	1.631
2 capas (16, 8)	1.131 ± 1.078	2.416	72.824	6.385	14.51	1.562
2 capas (64, 16)	1.118 ± 1.125	2.404	71.978	6.582	14.956	1.586
2 capas (32, 32)	1.089 ± 1.251	2.357	69.38	6.904	15.688	1.659
2 capas (128, 32)	1.259 ± 1.265	2.705	64.546	7.631	17.341	1.785
3 capas (32, 16, 8)	1.08 ± 1.181	2.32	71.47	7.116	16.17	1.601
3 capas (16, 32, 16)	1.106 ± 1.139	2.377	71.925	7.346	16.693	1.588
3 capas (32, 32, 16)	1.188 ± 1.145	2.552	69.667	6.874	15.621	1.651
3 capas (64, 32, 16)	1.155 ± 1.162	2.486	70.11	6.716	15.262	1.639

OPTIMIZACIÓN DE FUNCIÓN DE ACTIVACIÓN

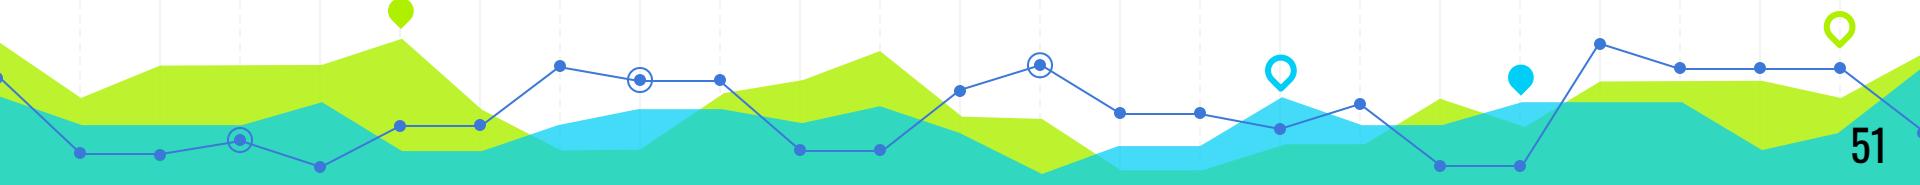
Activation	MAE ± STD °C	MAPE %	R ² %	MáxAE °C	MáxAPE %	RMSD °C
Softmax	1.295 ± 1.033	2.766	69.461	4.952	11.252	1.657
Elu	0.969 ± 0.949	2.098	79.54	4.405	10.011	1.356
Selu	1.135 ± 0.979	2.449	75.007	5.103	11.596	1.499
Softplus	1.33 ± 0.952	2.817	70.242	5.025	11.418	1.635
Softsign	1.302 ± 1.012	2.769	69.763	4.98	11.316	1.649
Relu	1.079 ± 0.852	2.306	78.965	4.209	9.441	1.375
tanh	0.911 ± 0.886	1.959	82.044	4.444	9.875	1.27
Sigmoid	1.289 ± 0.904	2.737	72.426	4.939	11.224	1.574
Hard Sigmoid	1.12 ± 0.945	2.402	76.127	4.693	10.665	1.465
Linear	0.99 ± 1.185	2.152	73.462	6.284	14.28	1.544

MÉTRICAS DE EVALUACIÓN

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - x_j|$$

$$STD = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \mu)^2}$$

$$MAPE = \frac{1}{n} \sum_{j=1}^n \left| \frac{y_j - x_j}{y_j} \right| \cdot 100\%$$



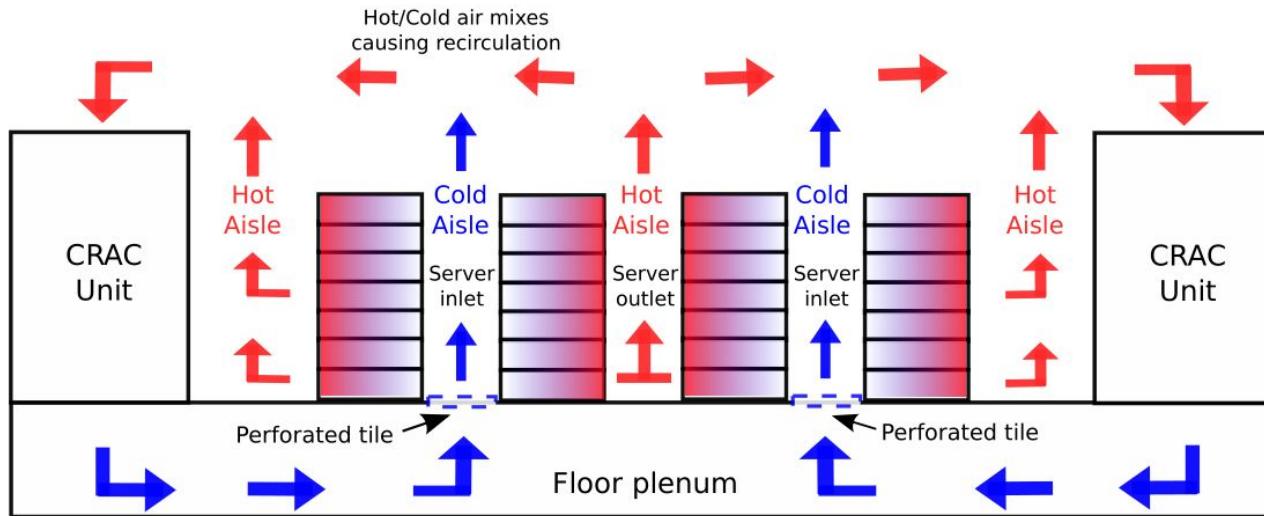
MÉTRICAS DE EVALUACIÓN

$$R^2 = \frac{\sum_{j=1}^n (y_j - x_j)^2}{\sum_{j=1}^n (y_j - \bar{y}_j)^2}$$

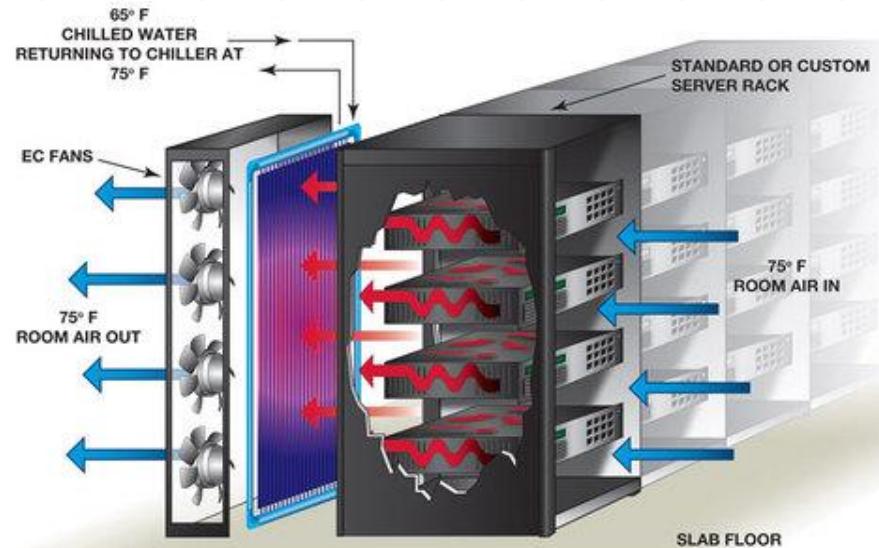
$$RMSD = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - x_j)^2}$$



UNIDAD CRAC DE REFRIGERACIÓN

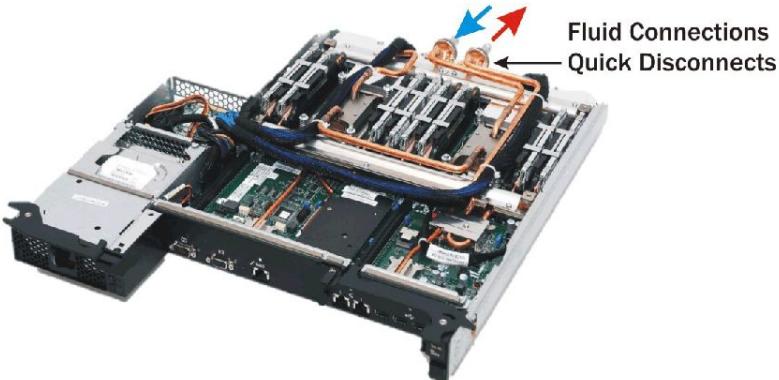


REFRIGERACIÓN POR PUERTAS TRASERAS ACTIVAS



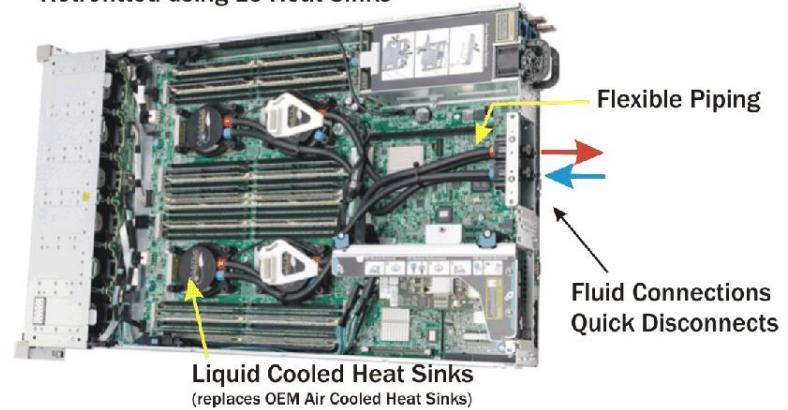
REFRIGERACIÓN LÍQUIDA DIRECTA DE UNA FASE

OEM Server using hard copper piping

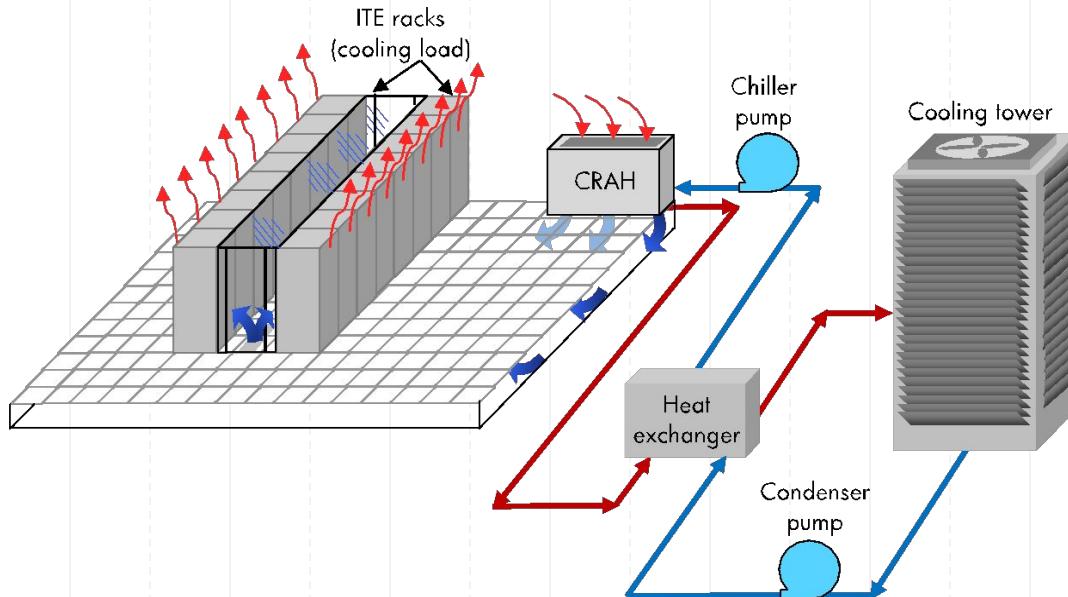


Standard OEM Server

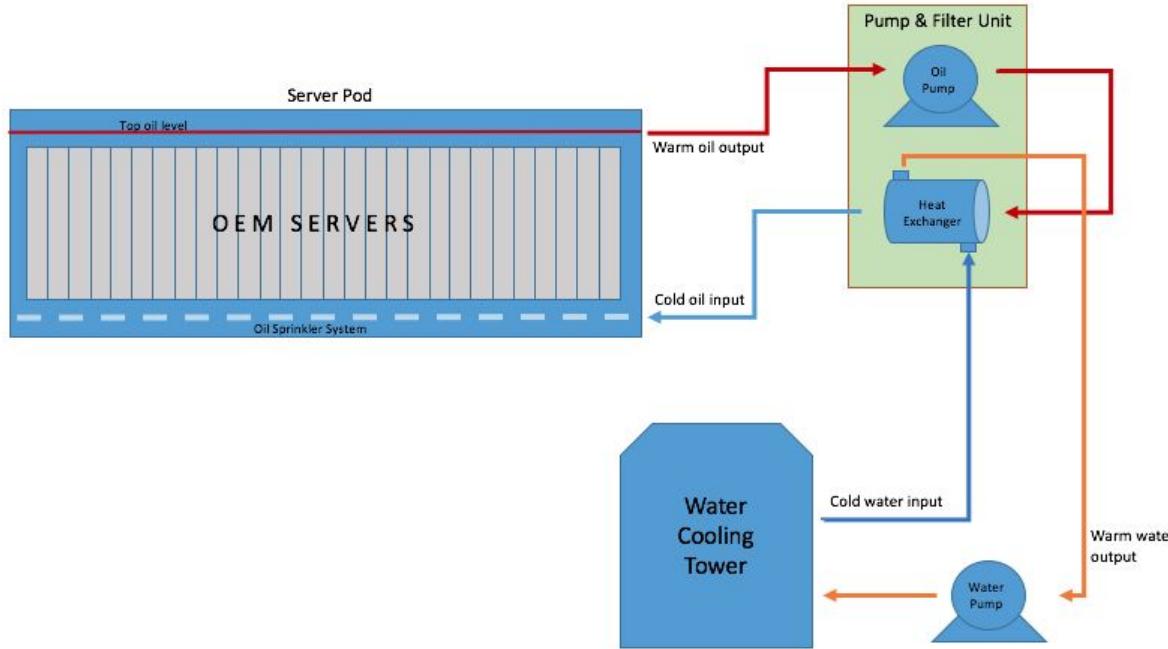
Retrofitted using LC Heat Sinks



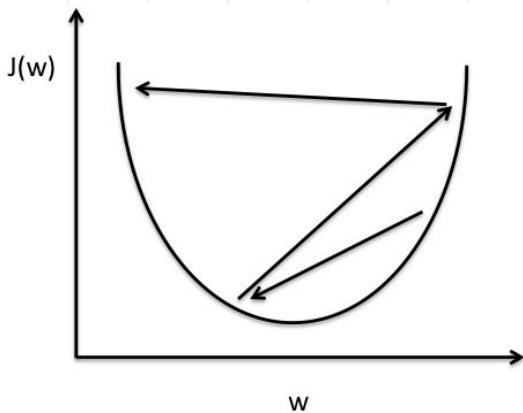
UNIDAD CRAH DE REFRIGERACIÓN



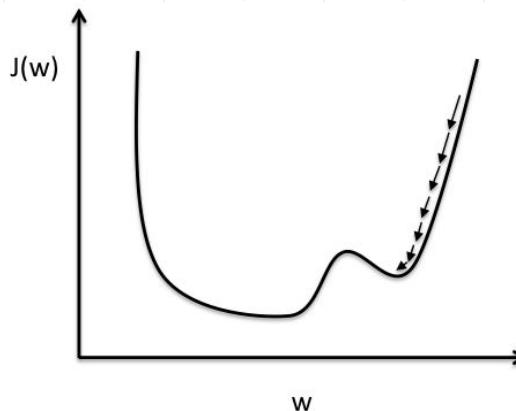
REFRIGERACIÓN POR INMERSIÓN EN UNA FASE



MÉTODOS METAHEURÍSTICOS



Large learning rate: Overshooting.



Small learning rate: Many iterations until convergence and trapping in local minima.



ESTADO DEL ARTE: EJEMPLOS DE APLICACIÓN DE RNN

- [23] M. Akram, C., «Sequence to Sequence Weather Forecasting with Long Short-Term Memory Recurrent Neural Networks,» *International Journal of Computer Applications* (0975 - 8887) Volume 143 - No.11, June 2016
- [24] Z. Che, S. Purushotham, K. Cho, D. Sontag, Y. Liu, «Recurrent Neural Networks for Multivariate Time Series with Missing Values,» *Nature Scientific Reports*, (2018) DOI:10.1038/s41598-018-24271-9
- [25] J. Xu, R. Rahmatizadeh, L. Bölöni and D. Turgut, «Real-Time Prediction of Taxi Demand Using Recurrent Neural Networks,» in *IEEE Transactions on Intelligent Transportation Systems*.
doi: 10.1109/TITS.2017.2755684
- [26] B. Kermanshahi, «Recurrent neural network for forecasting next 10 years loads of nine Japanese utilities,» *Neurocomputing*, Volume 23, Issues 1–3, 1998, Pages 125-133, ISSN 0925-2312

CARGA DE TRABAJO: PREDICCIÓN DE CONTAMINACIÓN AMBIENTAL EN PEKÍN

- Fecha y hora.
- PM2,5: Concentración de partículas en suspensión de menos de 2,5 micras (medida estándar de contaminación ambiental).
- DEWP: Punto de rocío, que depende de la temperatura y la humedad relativa.
- Temperatura.
- Presión atmosférica.
- CBWD: Dirección combinada del viento.
- LSW: Velocidad del viento acumulada.
- LS: Horas de nevada acumuladas.
- LR: Horas de lluvia acumuladas.



UCIRVINE



PERFIL DE TEMPERATURA

